Classification Multi-Label

PRÉDICTION DE LA RÉADMISSION DES PATIENTS DIABÉTIQUES

Domaine : Healthcare + Data Science

Analyse et modélisation avec Machine Learning

Présenté par:

Ghada Ben Mansour

Groupe 3

PLAN

Plan

1 Contexte

2 problematique

3 Objectifs

4 Comprehension des donnees

5 1. Exploratory Data Analysis (EDA)

5 2. Data Cleaning & Preprocessing

5 3. feature engineering

5 4. Modeling

6 Comparaison des modeles

1. CONTEXTE

Contexte

Le secteur hospitalier fait face à un défi majeur :
la réadmission des patients, en particulier dans les maladies chroniques comme le diabète.

Les réadmissions hospitalières sont fréquentes et coûteuses
Les hôpitaux cherchent à :

- réduire les réadmissions
- optimiser les traitements
- améliorer la prise en charge

2. PROBLEMATIQUE

problematique

Les réadmissions fréquentes entraînent plusieurs problèmes critiques :

- Perte de ressources médicalesmobilisation inutile du personnel soignant
- Occupation des litssaturation des services hospitaliers
- Surconsommation de médicaments et traitements
- Augmentation des coûts hospitaliers
- Diminution de la qualité de prise en charge

problematique

Comment prédire :
si un patient sera réadmis
s'il y aura un changement de traitement
à partir de données médicales historiques complexes

Difficultés

- données déséquilibrées
- variables hétérogènes (numériques + catégorielles)
- relations non linéaires
- risque de data leakage

3. OBJECTIFS

Objectifs

OBJECTIF 1

Construire un modèle prédictif fiable

OBJECTIF 2

Identifier les patients à risque

OBJECTIF 3

Comprendre les facteurs influents

OBJECTIF 4

Gérer le déséquilibre des classes

OBJECTIF 5

Éviter le data leakage

4. COMPREHENSION DES DONNEES

Phase 1 : data understanding:

CHARGEMENT DU DATASET

Diabetic Data (Hospital Readmission Dataset)

TAILLE

```
Dimensions du dataset : (101766, 50)
```

```
Types des colonnes :
object    37
int64     13
```

STRUCTURE

Pour comprendre sa structure, nous avons inspecté les données à l'aide de commandes de base comme df.head(), df.shape , df.info()... dans la phase d'EDA

Variables cibles

Le projet est un problème multi-label classification :

- **readmitted_bin** — indique si le patient est réadmis à l'hôpital
- **change_bin** — indique s'il y a eu un changement de traitement

Particularité du dataset

- Données médicales réelles
- Présence de déséquilibre entre classes
- Forte complexité relationnelle entre variables

5.1. EXPLORATORY DATA ANALYSIS (EDA)

Exploratory Data Analysis (EDA)

L'EDA (Exploratory Data Analysis) est une étape essentielle qui permet de comprendre en profondeur les données avant la phase de modélisation. Elle repose sur :

ÉTAPE 1 : CHARGEMENT & COMPRÉHENSION

ÉTAPE 2 : ANALYSE DES VARIABLES

ÉTAPE 3 : VALEURS MANQUANTES

```
Colonnes à fort taux NaN  :
  - weight (96.9%)
  - max_glu_serum (94.8%)
  - A1Cresult (83.3%)
  - medical_specialty (49.1%)
  - payer_code (39.6%)
```

ÉTAPE 4 : STATISTIQUES DESCRIPTIVES

ÉTAPE 5 : DISTRIBUTION DES DONNÉES

Visualisation (matplotlib)

ÉTAPE 6 : DÉTECTION DES OUTLIERS

Boxplots et Méthode IQR

ÉTAPE 7 : VARIABLES CATÉGORIELLES

value_counts() et barplots

ÉTAPE 8 : ANALYSE DES CIBLES

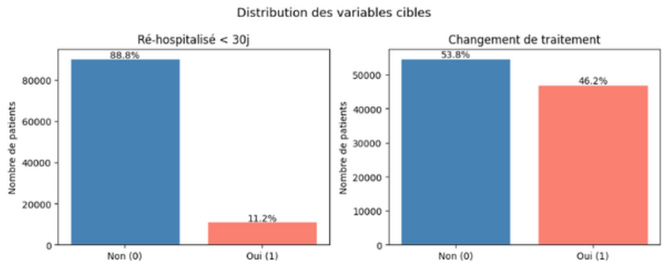

ÉTAPE 9 : CORRÉLATIONS

Matrice de corrélation (heatmap)
Corrélation de Pearson

5.2 DATA CLEANING & PREPROCESSING

Data Cleaning & Preprocessing

La phase de Data Cleaning et Preprocessing a pour objectif d'améliorer la qualité des données avant la modélisation.

1.SUPPRESSION DES COLONNES INUTILES

- identifiants (encounter_id)
- colonnes avec trop de NaN (weight, medical_specialty)
- colonnes constantes (examide, citoglipton)
- colonnes peu utiles (payer_code)

2.TRAITEMENT DES DUPLICATIONS

On garde les visites multiples car elles contiennent des informations importantes (historique patient)

3.NETTOYAGE DE GENDER

```
gender
Female            54708
Male              47055
Unknown/Invalid       3
```

4.TRANSFORMATION DES DIAGNOSTICS

Regroupement des codes médicaux (ICD-9)

trop de valeurs uniques (complexe)

5.TRANSFORMATION DES VARIABLES CIBLES

```
readmitted_bin : {0: 90406, 1: 11357}
change_bin     : {0: 54754, 1: 47009}
```

6.TRAITEMENT DES VALEURS MANQUANTES

Variables numériques : Remplacement par la médiane plus fiable que la moyenne

Variables categorielles :

"**Unknown**"- ex : race --- quand info importante mais manquante
"**Autre**" -ex : diagnostics --- logique métier
Mode (valeur la plus fréquente) pour les autres colonnes

5.3 FEATURE ENGINEERING

feature engineering

Les buts de cette phase sont :
Créer de nouvelles variables plus intelligentes, améliorer la qualité du dataset et augmenter la performance des modèles ML

ÉTAPE 1 : TRANSFORMATION DES MÉDICAMENTS

Création de 2 nouvelles variables :
nb_meds_actifs : nombre de médicaments pris (≠ "No")
nb_meds_modifies :

- nombre de médicaments modifiés ("Up" / "Down")
- Suppression des colonnes médicaments

But : réduction de dimension

ÉTAPE 2 : SUPPRESSION FINALE DE COLONNES INUTILES

Suppression de médicaments rares ou inutiles

ÉTAPE 3 : TRANSFORMATION DE L'ÂGE

Transformation : [60-70) → 65 (milieu)
Création d'une nouvelle variable is_senior
+ 1 si âge ≥ 65
+ 0 sinon
Suppression de age

ÉTAPE 4 : CRÉATION DE VARIABLES AVANCÉES

1. total_visits : total des visites (urgence + hospitalisation + externe)
2. procedures_per_day : intensité des soins
3. meds_per_diag :complexité traitement vs maladies
4. nb_visites_patient :nombre total de visites par patient

ÉTAPE 5 : DÉTECTION DE DATA LEAKAGE

Analyse de corrélation
Résultat :

- nb_meds_actifs → corrélation très forte (0.71) avec change_bin

problème : le modèle "voit" la réponse directement
Décision :

- supprimer : nb_meds_actifs, nb_meds_modifies, diabetesMed

5.4 MODELING *Modeling*

Les buts de cette phase sont :
Entraîner plusieurs modèles, gérer le multi-label et le déséquilibre ,optimiser les performances, choisir le meilleur modèle

ÉTAPE 1 : CHARGEMENT & SUPPRESSION DU DATA LEAKAGE

Suppression de : nb_meds_actifs , nb_meds_modifies , diabetesMed

ÉTAPE 2 : SÉPARATION X / Y

X = Features
y = 2 cibles : readmitted_bin , change_bin

ÉTAPE 3 : TRAIN / TEST SPLIT

80% train / 20% test
stratification sur readmitted_bin
But : garder le même déséquilibre dans train/test

ÉTAPE 4 : PREPROCESSING

Pipeline avec ColumnTransformer

- Numériques → médiane + scaling
- Binaires → encoding
- Ordinales → ordre respecté
- Catégorielles → OneHotEncoding

ÉTAPE 5 : GESTION DU DÉSÉQUILIBRE

Utilisation de : class_weight ((RandomForest, LightGBM)) et scale_pos_weight(XGBoost) (pas de smote)

ÉTAPE 6 : MODÉLISATION (CLASSIFIERCHAIN)

ClassifierChain + RF + XGB + LGBM

ÉTAPE 7 : OPTIMISATION DU THRESHOLD

Pas de seuil fixe (0.5)
Calcul du meilleur seuil avec :

- Precision-Recall curve
- maximisation du F1-score

But :mieux détecter les classes rares

ÉTAPE 8 : ÉVALUATION

Métriques : Precision , Recall , F1 Macro, ROC-AUC

ÉTAPE 9 : SÉLECTION DU MEILLEUR MODÈLE

Mean ROC-AUC

5.4 MODELING

Modeling

```
ordinal_encoder = OrdinalEncoder(categories=[a1c_order, glu_order])

preprocessor = ColumnTransformer([
    ('num', Pipeline([
        ('imputer', SimpleImputer(strategy='median')),
        ('scaler',  RobustScaler())
    ]), cols_numeriques),

    ('bin', Pipeline([
        ('imputer', SimpleImputer(strategy='most_frequent')),
        ('encoder', OneHotEncoder(drop='if_binary'))
    ]), cols_binaires),

    ('ord', Pipeline([
        ('imputer', SimpleImputer(strategy='most_frequent')),
        ('encoder', ordinal_encoder)
    ]), cols_ordinales),

    ('cat', Pipeline([
        ('imputer', SimpleImputer(strategy='most_frequent')),
        ('encoder', OneHotEncoder(handle_unknown='ignore'))
    ]), cols_onehot)
])

X_train_proc = preprocessor.fit_transform(X_train)
X_test_proc  = preprocessor.transform(X_test)
```

6. COMPARAISON DES MODELES

Comparaison des modeles

Random Forest

Random Forest est un modèle d'apprentissage supervisé basé sur un ensemble d'arbres de décision (ensemble learning).

XGBoost

XGBoost (Extreme Gradient Boosting) est un algorithme de boosting basé sur des arbres de décision optimisés.

LightGBM

LightGBM (Light Gradient Boosting Machine) est une version optimisée du boosting, conçue pour être plus rapide et plus efficace.

```
============================================================
  COMPARAISON DES MODÈLES — ROC-AUC MOYEN
============================================================

 RandomForest
   readmitted_bin       : ROC-AUC = 0.7775
   change_bin           : ROC-AUC = 0.6965
   Mean ROC-AUC         : 0.7370

 XGBoost
   readmitted_bin       : ROC-AUC = 0.7924
   change_bin           : ROC-AUC = 0.7100
   Mean ROC-AUC         : 0.7512

 LightGBM
   readmitted_bin       : ROC-AUC = 0.7903
   change_bin           : ROC-AUC = 0.7097
   Mean ROC-AUC         : 0.7500

============================================================
  MEILLEUR MODÈLE : XGBoost
  Mean ROC-AUC    : 0.7512
============================================================
```

7. CONCLUSION ET PERSPECTIVES

conclusion et perspectives

conclusion

Ce projet a permis de construire un pipeline complet de Machine Learning appliqué au domaine médical, depuis l'exploration et le nettoyage des données jusqu'à la modélisation multi-label.
Les étapes de preprocessing et de feature engineering ont permis d'obtenir un dataset cohérent et exploitable.
L'utilisation de ClassifierChain a permis de prendre en compte les dépendances entre les cibles, améliorant ainsi la qualité des prédictions. La comparaison des modèles (Random Forest, XGBoost, LightGBM) à l'aide du ROC-AUC a permis d'identifier le modèle le plus performant.

perspectives

Les améliorations futures incluent l'optimisation des hyperparamètres avec GridSearchCV ou RandomizedSearchCV, une meilleure gestion du déséquilibre des classes, l'exploration de modèles plus avancés et l'amélioration du feature engineering. Le déploiement du modèle et l'ajout de méthodes d'interprétabilité sont également envisagés pour une utilisation réelle.

MERCI DE VOTRE ATTENTION !